UNIVERSIDAD ANDRÉS BELLO

Magíster en Ciencia de Datos e Inteligencia Artificial

MCDI501
Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Relación entre condiciones meteorológicas y lluvia al día siguiente

Informe técnico grupal · Grupo 7 · Ponderación 20 %

Integrantes

Benjamín Araya
Alan Cañete
Patricio Cortez
Jorge Guaico

Dataset: Rain in Australia — Weather Australia
Docente: Jean Paul Maidana
Fecha: 13 de octubre de 2026

Repositorio y rama del análisis

https://github.com/BenjaArayaM/Proyecto-Lluvias-Australia-Grupo7

Contenido

1. Preparación y carga de datos 3
2. Análisis exploratorio de datos 4
2.1 Estadística descriptiva y forma de las distribuciones 4
2.2 Relaciones entre variables meteorológicas 5
3. Estimación de parámetros 6
3.1 Medias meteorológicas por localidad 6
3.2 Proporción de lluvia agrupada y por localidad 6
4. Pruebas de hipótesis 7
4.1 Diferencias de humedad por localidad 7
4.2 Asociación entre lluvia hoy y lluvia mañana 8
4.3 Dependencia temporal y sensibilidad por localidad 9
Dependencia temporal de la humedad 9
Sensibilidad de la asociación entre lluvia actual y posterior 9
5. Informe de avance del proyecto 10
6. Notebook y repositorio GitHub 10
7. Bibliografía (APA 7) 11

Pregunta de investigación

¿Qué relación existe entre las condiciones meteorológicas de un día y la ocurrencia de lluvia al día siguiente?

El desarrollo ocupa las páginas 3 a 10. La portada, el índice y la bibliografía se presentan en páginas independientes. Los resultados ampliados se consultan en el notebook y en las exportaciones del repositorio.

1. Preparación y carga de datos

Estudiamos la relación entre las condiciones meteorológicas de un día y la lluvia posterior, con continuidad respecto de la Formativa 1 del grupo (Araya et al., 2026a). Utilizamos weatherAUS.csv, publicado como Rain in Australia por jsphyg (s. f.), con datos del Bureau of Meteorology procesados en Rattle (Williams, s. f.). La unidad observada es una localidad en una fecha. RainTomorrow es el objetivo binario: Yes indica lluvia superior a 1 mm al día siguiente.

La carga con pandas y la conversión de Date identifican 145.460 registros, 23 variables y 49 localidades, entre el 01/11/2007 y el 25/06/2017. Hay 16 columnas numéricas: temperaturas, humedad, presión, lluvia, evaporación, sol, viento y nubosidad codificada. Location, las tres direcciones del viento y RainToday/RainTomorrow son categorías; Date es temporal. Los tipos estadísticos se distinguen del almacenamiento numérico.

Tabla 1. Auditoría inicial y decisiones de tratamiento

Comprobación	Resultado y decisión
Duplicados exactos y localidad–fecha	0 en ambos controles; no se elimina ningún registro por duplicación.
Fechas y consistencia física	0 fechas inválidas, 0 MinTemp > MaxTemp, 0 lluvias negativas y 0 humedades fuera de 0–100 %.
Objetivo y faltantes	3.267 RainTomorrow ausentes (2,25 %); no se imputan ni se convierten en No.
Casos completos y extremos	56.420 filas completas (38,79 %); se usan casos disponibles por cálculo y se conservan extremos sin evidencia de error.

Eliminar todas las filas incompletas descartaría el 61,21 %; por ello se usan casos disponibles. Tampoco se sustituye por media o mediana, pues podría reducir artificialmente la dispersión y alterar asociaciones. La ausencia puede sesgar los casos disponibles: conservar información no garantiza ausencia de sesgo. El original permanece intacto y cada análisis declara su denominador.

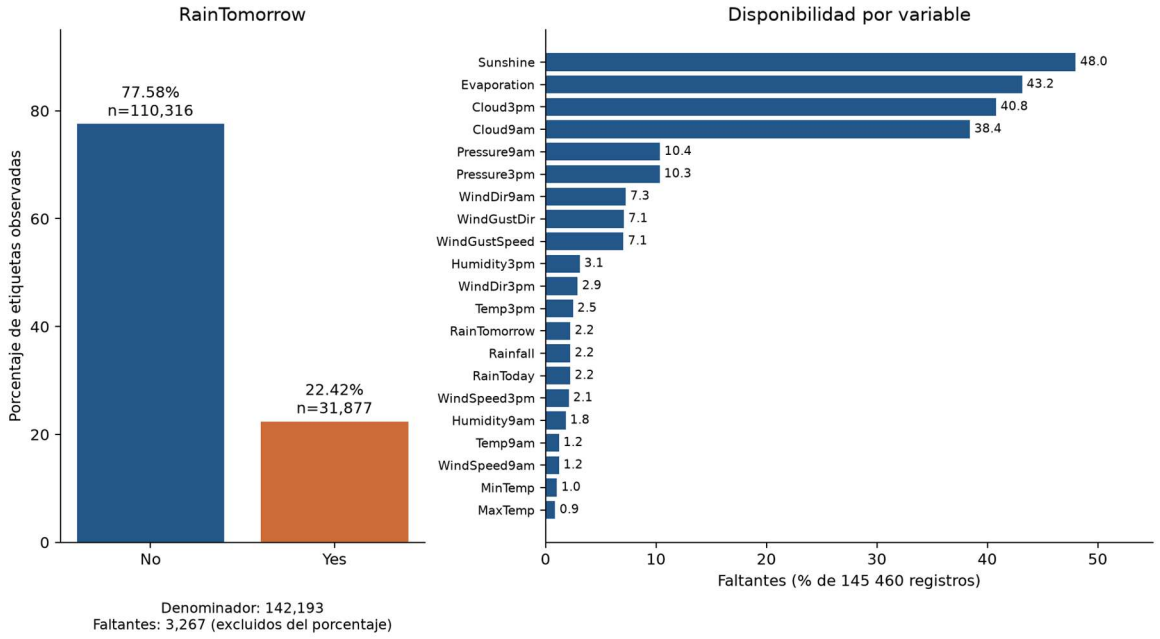


Figura 1. Frecuencias de RainTomorrow y faltantes por variable. Entre 142.193 etiquetas conocidas: No = 110.316 (77,58 %) y Yes = 31.877 (22,42 %). Faltantes calculados sobre 145.460 filas. Fuente: Formativa 1 del grupo.

2. Análisis exploratorio de datos

2.1 Estadística descriptiva y forma de las distribuciones

La Tabla 2 resume seis variables meteorológicas. La desviación estándar (DE), la asimetría y la curtosis en exceso (convención de Fisher) se calcularon con pandas a partir de los casos disponibles; la DE utiliza n−1. Esta descripción agrupa registros, mientras que las estimaciones inferenciales de la sección 3 asignan igual peso a cada localidad. La humedad se expresa en porcentaje y sus diferencias en puntos porcentuales (pp).

Tabla 2. Estadística descriptiva, curtosis y disponibilidad

Variable y unidad	n	Media	Mediana	DE	Asimetría	Faltantes %	Curtosis
Humidity3pm (%)	140.953	51,54	52,00	20,80	0,03	3,10	−0,51
Rainfall (mm)	142.199	2,36	0,00	8,48	9,84	2,24	178,15
Sunshine (h)	75.625	7,61	8,40	3,79	−0,50	48,01	−0,83
Pressure3pm (hPa)	130.432	1.015,26	1.015,20	7,04	−0,05	10,33	0,13
MaxTemp (°C)	144.199	23,22	22,60	7,12	0,22	0,87	−0,22
MinTemp (°C)	143.975	12,19	12,00	6,40	0,02	1,02	−0,48

Rainfall presenta una distribución muy asimétrica: media 2,36 mm, mediana 0 mm, asimetría 9,84 y curtosis en exceso 178,15. Este último valor refleja colas muy pesadas respecto de la normal, coherentes con observaciones de lluvia extrema (máximo 371 mm). Hay 2.128 registros por encima de 30 mm. La Figura 2 conserva la distribución completa y amplía el tramo 0–30 mm, sin eliminar datos.

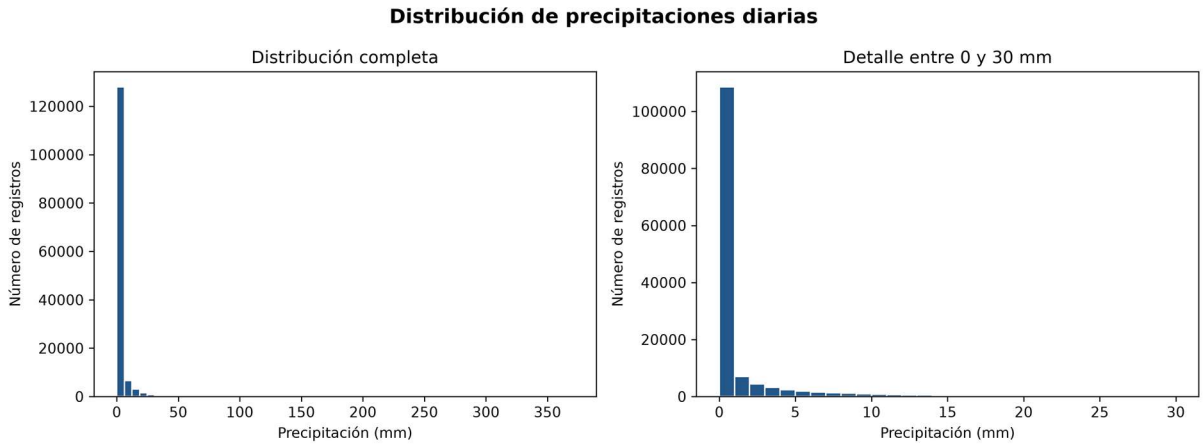


Figura 2. Distribución de las precipitaciones en 142.199 registros. Vista completa y detalle 0–30 mm. Fuente: notebook de Sumativa 1.

Humidity3pm y Pressure3pm muestran poca asimetría global (0,03 y −0,05); esto no demuestra normalidad. La humedad abarca 0–100 % y la presión 977,1–1.039,6 hPa. MaxTemp varía de −4,8 a 48,1 °C y MinTemp de −8,5 a 33,9 °C. Estos rangos combinan diferencias diarias y geográficas.

Los faltantes se concentran en Sunshine (48,01 %), Evaporation (43,17 %), Cloud3pm (40,81 %) y Cloud9am (38,42 %), según la Figura 1. En la Formativa 1, Sunshine está ausente en todos los registros de 19 localidades; no es prudente asumir un mecanismo completamente aleatorio. Los códigos Cloud = 9 se conservan como códigos especiales pendientes de interpretación, sin tratarlos como nueve octas físicas.

2.2 Relaciones entre variables meteorológicas

La matriz de Spearman describe asociaciones monotónicas entre siete variables y permite comparar información relacionada sin exigir normalidad. Se usan casos disponibles por par; no todas las celdas representan las mismas observaciones. La Figura 3 incorpora la relación entre predictores solicitada en la retroalimentación de la Formativa 1.

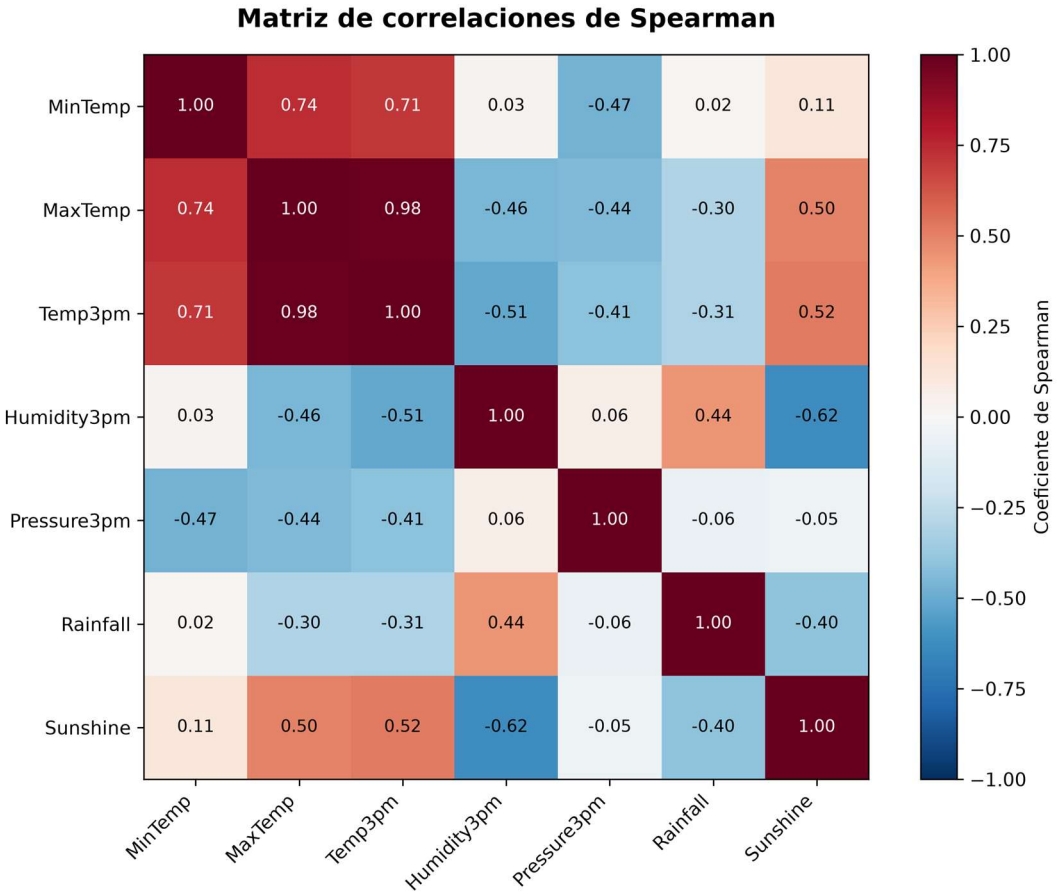


Figura 3. Correlaciones de Spearman entre condiciones meteorológicas. Coeficientes redondeados a dos decimales. Los n de cada par se conservan en n_pares_correlaciones.csv. Fuente: notebook de Sumativa 1.

MaxTemp y Temp3pm están estrechamente relacionadas (ρ = 0,984; n = 141.589), lo que advierte redundancia para un modelo futuro. MinTemp y MaxTemp también se asocian positivamente (ρ = 0,738; n = 143.579), aunque no son mediciones intercambiables.

Humidity3pm y Sunshine presentan una relación negativa (ρ = −0,620; n = 74.497). Humidity3pm y Rainfall se asocian positivamente (ρ = 0,444; n = 138.569), mientras Rainfall y Sunshine se relacionan negativamente (ρ = −0,401; n = 74.379). Estos resultados describen las mediciones del registro y pueden reflejar mezcla de localidades, períodos y disponibilidad de datos.

La matriz no incluye RainTomorrow: no permite ordenar directamente la capacidad predictiva de sus variables. La relación de humedad con el objetivo se estudia en la sección 4.1, y la persistencia de lluvia en la sección 4.2. Correlación entre predictores, asociación con el objetivo y desempeño de un clasificador son conceptos distintos.

3. Estimación de parámetros

3.1 Medias meteorológicas por localidad

Para Humidity3pm, MaxTemp y MinTemp calculamos primero una media histórica en cada localidad y luego promediamos las 49 medias con igual peso, como en la Formativa 1. El parámetro del modelo es la media de medias locales comparables; el resumen de las 49 localidades observadas es un valor descriptivo exacto. La inferencia no representa automáticamente una media nacional.

$$IC\ 95\ \% = \bar{x}_{local} \pm 2{,}010635 \times \frac{s_{local}}{\sqrt{49}}$$

El intervalo t usa 48 grados de libertad y la DE entre medias locales, no la DE de las filas diarias. El modelo requiere independencia aproximada entre localidades y una distribución de resúmenes compatible con la aproximación t (The SciPy community, s. f.-c). En F1, Shapiro no rechazó normalidad de esos resúmenes; los desvíos de cola del Q-Q mantienen el carácter aproximado.

Tabla 3. Estimaciones e intervalos nominales del 95 %

Parámetro	Unidad de análisis	Estimación	IC 95 %	Método
Humedad a las 15:00 (%)	49 medias locales	51,25	48,02–54,47	t, gl = 48
Temperatura máxima (°C)	49 medias locales	23,39	22,22–24,55	t, gl = 48
Temperatura mínima (°C)	49 medias locales	12,26	11,12–13,39	t, gl = 48
Lluvia posterior (%)	142.193 etiquetas	22,42	22,20–22,64	Wilson
Lluvia posterior (%)	49 proporciones locales	22,19	20,24–24,14	t, gl = 48

3.2 Proporción de lluvia agrupada y por localidad

El intervalo agrupado usa 31.877 Yes entre 142.193 etiquetas conocidas; excluye 3.267 respuestas ausentes. Wilson se obtiene por inversión del contraste binomial de puntuación y mantiene los límites en el rango de una proporción (Wilson, 1927). Se conserva el método ejecutado en el notebook: no equivale a una corrección de la dependencia temporal o geográfica.

La media de proporciones locales es 22,19 %, con IC t 20,24–24,14 %. Es un estimando diferente del 22,42 % agrupado: cada localidad pesa igual en el primero y cada etiqueta observada pesa igual en el segundo. La amplitud mayor refleja variabilidad entre localidades y otra unidad de análisis; no valida por sí sola la cobertura nominal.

Woomera registra 6,76 % y Portland 36,55 % de lluvia posterior. Las diferencias de cobertura impiden interpretar esta comparación como una climatología nacional equilibrada. El 95 % se refiere a la cobertura del procedimiento bajo su modelo, no al 95 % de los días ni a una probabilidad posterior sobre el parámetro. Los cinco intervalos son individuales, sin garantía conjunta del 95 %.

4. Pruebas de hipótesis

4.1 Diferencias de humedad por localidad

Usamos $\alpha = 0{,}05$ como umbral convencional de referencia para el error de tipo I bajo el modelo. Los contrastes son exploratorios y sus valores p individuales no incluyen ajuste por multiplicidad. La decisión se interpreta junto con magnitud, incertidumbre y supuestos, sin presentar el umbral como garantía de relevancia práctica.

En cada localidad calculamos D = humedad media con RainTomorrow = Yes menos humedad media con No. Contrastamos H_0: $\mu D = 0$ frente a H_1: $\mu D \neq 0$ mediante una t de una muestra sobre las 49 diferencias, equivalente a una t pareada de medias locales. El emparejamiento vincula medias de la misma localidad; no empareja días individuales (The SciPy community, s. f.-c).

Tabla 4. Prueba t sobre las diferencias locales de humedad

Resultado	Valor
Registros utilizados y excluidos	138.583 utilizados; 6.877 excluidos por humedad u objetivo ausentes
Diferencia e IC nominal del 95 %	20,08 pp; IC = 18,47–21,68 pp
Estadístico, grados de libertad y p	$t = 25{,}1461$; $gl = 48$; $p = 2{,}7471 \times 10^{-29}$
Tamaño del efecto y signo	$d_z = 3{,}5923$; diferencias positivas en 49 de 49 localidades

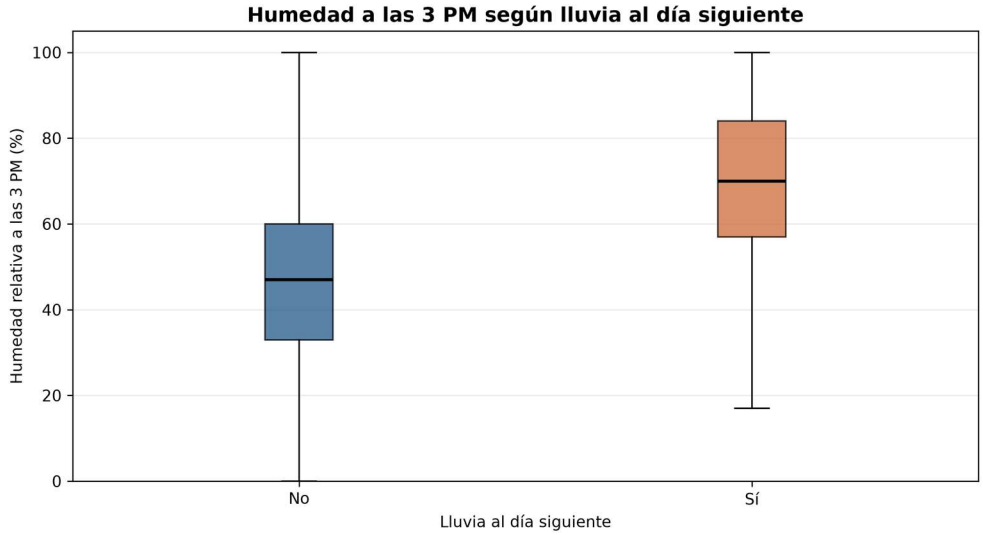


Figura 4. Humedad vespertina según lluvia al día siguiente. No: n = 107.670; Yes: n = 30.913. Los puntos exteriores se ocultan solo en el dibujo y se conservan en los cálculos. Fuente: notebook de Sumativa 1.

Shapiro-Wilk sobre las diferencias da $W = 0{,}9884$ y $p = 0{,}9059$; el Q-Q es aproximadamente lineal. No rechazar normalidad no demuestra normalidad ni independencia (The SciPy community, s. f.-b). La prueba sobre diferencias no requiere igualdad de varianzas de los dos grupos diarios. La independencia entre localidades sigue sin verificarse.

Bajo el modelo se rechaza H_0. La diferencia va de 6,57 pp en Albany a 33,34 pp en AliceSprings. d_z estandariza por la variabilidad entre diferencias locales: no mide un efecto individual diario. La Figura 4 muestra solapamiento; su diferencia agrupada de medias es 22,29 pp, distinta del promedio local de 20,08 pp. La humedad queda como candidata, sin demostrar causalidad ni clasificación eficaz.

4.2 Asociación entre lluvia hoy y lluvia mañana

Contrastamos H_0: RainToday y RainTomorrow son independientes frente a H_1: están asociados, con $\alpha = 0{,}05$. La prueba χ^2 de Pearson se aplica a 140.787 registros con ambas etiquetas conocidas; excluye 4.673 filas. Se usa correction=False, sin corrección de Yates, tal como fue ejecutado en el notebook (The SciPy community, s. f.-a).

Tabla 5. Contingencia de lluvia actual y posterior

RainToday	Mañana No	Mañana Yes	Total	Yes por fila %
No	92.728	16.604	109.332	15,19
Yes	16.858	14.597	31.455	46,41
Total	109.586	31.201	140.787	22,16

Se obtiene $\chi^2 = 13.801{,}2894$, gl = 1 y p clásico < 0,001; bajo el modelo se rechaza H_0. La salida numérica p = 0 corresponde a subdesbordamiento y no a una probabilidad exactamente nula. V de Cramér = 0,3131 cuantifica la intensidad de asociación en esta tabla, sin medir precisión predictiva ni efecto causal.

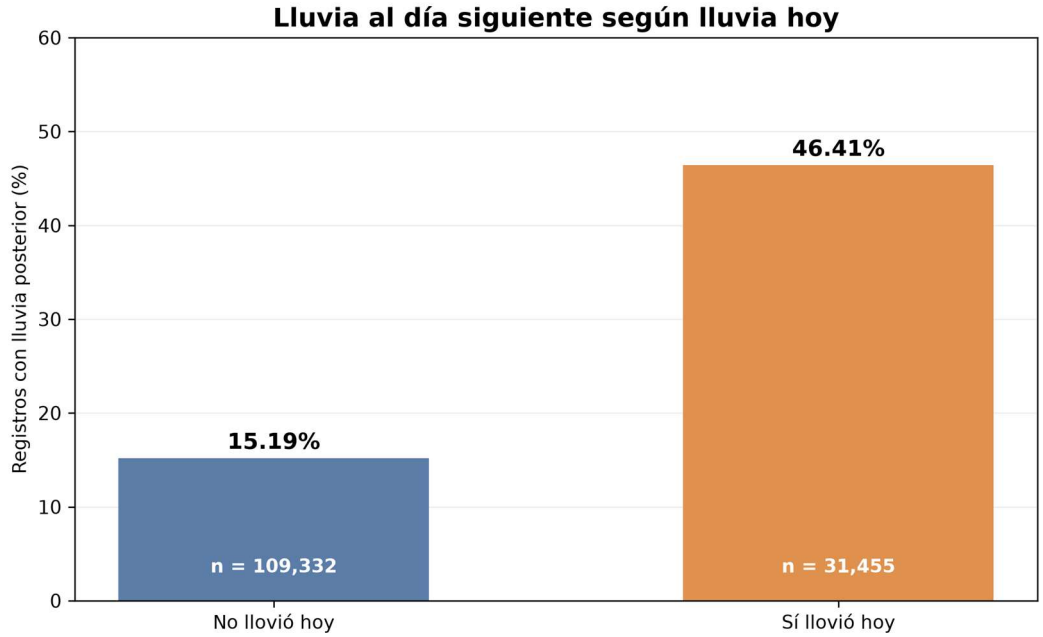


Figura 5. Porcentaje de lluvia posterior según lluvia actual. Porcentajes calculados dentro de cada categoría de RainToday sobre los registros de la Tabla 5. Fuente: notebook de Sumativa 1.

La frecuencia esperada mínima bajo H_0 es 6.971,01 y las cuatro esperadas superan 5; las categorías son excluyentes y se usan conteos. Se cumple el criterio de frecuencias, pero la independencia entre observaciones no está garantizada: días consecutivos y localidades próximas pueden estar relacionados. Por ello, el p clásico se presenta como referencia, no como evidencia concluyente que ignore la estructura de los datos.

La proporción posterior es 46,41 % cuando llueve hoy y 15,19 % cuando no, una diferencia agrupada de 31,22 pp. Esto respalda descriptivamente la persistencia de lluvia que se mencionaba en F1. El contraste usa un subconjunto distinto del intervalo de la proporción global; su 22,16 % total no contradice el 22,42 % de la sección 3. La comparación local siguiente examina la estabilidad del signo.

4.3 Dependencia temporal y sensibilidad por localidad

Dependencia temporal de la humedad

Para diagnosticar dependencia calculamos Pearson entre Humidity3pm de una fecha y de la fecha anterior en la misma localidad. Solo se admiten separaciones de un día y humedad observada en ambos registros. No se enlazan artificialmente fechas separadas por vacíos ni se imputan mediciones.

La mediana de las 49 correlaciones lag-1 es 0,5023 y la media 0,5080. Albany presenta 0,1975 (2.301 pares) y Darwin 0,7556 (3.185 pares). La asociación temporal positiva desaconseja tratar las filas como réplicas independientes. Agrupar por localidad reduce la pseudorreplicación diaria, aunque no proporciona por sí solo un error estándar válido para dependencia espacial o cobertura desigual.

Sensibilidad de la asociación entre lluvia actual y posterior

En cada localidad calculamos la diferencia entre las proporciones de lluvia posterior con RainToday = Yes y No. Las 49 diferencias son positivas. Su promedio, con peso local igual, es 29,11 pp; IC t nominal = 27,02–31,19 pp, t = 28,0604, gl = 48 y $p = 1{,}9763 \times 10^{-31}$. Shapiro-Wilk da p = 0,5982, sin evidencia suficiente para rechazar normalidad de esas diferencias.

Tabla 6. Comparaciones agrupadas y con igual peso por localidad

Relación	Por registros	Por localidad	Lectura
Humedad y lluvia posterior	22,29 pp	20,08 pp	El signo coincide; cambian composición y ponderación.
Lluvia hoy y mañana	31,22 pp	29,11 pp	Diferencias positivas en las 49 localidades.

Tabla 7. Heterogeneidad local de la persistencia de lluvia

Localidad	Yes mañana si No hoy %	Yes mañana si Yes hoy %	Diferencia pp
Hobart	19,87	36,48	16,62
Melbourne	18,16	38,10	19,94
Albany	21,83	48,38	26,55
AliceSprings	4,99	42,74	37,75
Darwin	14,15	61,15	47,00

La Tabla 7 presenta cinco localidades para ilustrar heterogeneidad; las 49 se mantienen en sensibilidad_lluvia_por_localidad.csv. El signo común refuerza la asociación descriptiva y muestra que no depende únicamente de mezclar localidades. La magnitud tampoco es uniforme: Hobart y Darwin marcan los extremos de 16,62 y 47,00 pp.

Este complemento cambia la unidad de análisis y el estimando; no es una corrección del χ^2 ni una prueba de independencia espacial. Tampoco ajusta estacionalidad, diferencias de años observados o mecanismos de ausencia. No se ejecutaron remuestreo por bloques, modelos espaciales ni validación predictiva en esta sumativa; son posibles desarrollos posteriores.

5. Informe de avance del proyecto

La pregunta central se aborda mediante auditoría, descripción, correlaciones, intervalos y dos contrastes pertinentes. Los resultados respaldan dos asociaciones: mayor humedad vespertina antes de lluvia posterior y mayor frecuencia de lluvia mañana cuando llueve hoy. Su signo persiste en las 49 localidades, pero las magnitudes cambian entre ellas y según la ponderación. La correlación 0,984 entre MaxTemp y Temp3pm advierte información redundante.

Estos hallazgos orientan la selección de candidatos para apoyar decisiones agrícolas, hídricas o actividades expuestas a lluvia. No se ha entrenado un clasificador ni se han medido discriminación, calibración o costos de error. Significancia estadística y tamaño del efecto no acreditan capacidad predictiva; ninguna comparación establece causalidad.

El alcance está limitado por faltantes estructurados, cobertura histórica desigual, dependencia temporal observada y posible dependencia geográfica. La muestra no fue seleccionada como representación aleatoria de toda Australia. Las asociaciones y los intervalos describen este archivo y, en la inferencia, dependen del modelo declarado.

La curtosis solicitada en la retroalimentación ya fue calculada y documentada en el notebook. Los próximos pasos son revisar sensibilidad a períodos y regiones y planificar validación que respete tiempo y localidad. Antes del modelamiento se fijará la hora de emisión: Sunshine resume el día y la ráfaga máxima puede incluir mediciones hasta medianoche, por lo que no son automáticamente utilizables a las 15:00 (Williams, s. f.; Bureau of Meteorology, s. f.). Imputación y selección deberán ajustarse dentro del entrenamiento, declarando que el archivo completo ya fue explorado.

6. Notebook y repositorio GitHub

El análisis se documenta en 02_sumativa1_analisis.ipynb (Araya et al., 2026b), con código y explicaciones. La rama sumativa1-jorge contiene cinco figuras y once tablas, incluida la exportación de curtosis. La Tabla 8 señala las fuentes de los resultados del informe; las cifras descriptivas y de los contrastes también están en las salidas del cuaderno. Se conserva la metodología de F1 sin introducir procedimientos no ejecutados.

Tabla 8. Trazabilidad de los resultados y reproducción

Ruta dentro del proyecto	Contenido
notebooks/02_sumativa1_analisis.ipynb	Carga, auditoría, cálculos, supuestos e interpretaciones.
results/02_sumativa1/tables/	Auditoría, descriptivos, curtosis, correlaciones, IC, contingencia y sensibilidad.
results/02_sumativa1/figures/	Cinco visualizaciones generadas por el notebook.
docs/entorno_sumativa1_jorge.md	Versiones del entorno utilizado en Windows.
results/01_formativa1/	Evidencia previa y Figura 1 reutilizada sin cambiar el análisis.

Para reproducir, se requiere el CSV original en data/raw/weatherAUS.csv, las dependencias instaladas y ejecución desde notebooks con kernel reiniciado. El CSV no se distribuye en Git. Las versiones y la identidad del archivo permanecen en la documentación técnica; no sustituyen la verificación de supuestos.

Enlace directo al trabajo: https://github.com/BenjaArayaM/Proyecto-Lluvias-Australia-Grupo7

7. Bibliografía (APA 7)

Araya, B., Cañete, A., Cortez, P., & Guaico, J. (2026a). *Exploración e inferencia de lluvias en Australia* [Informe de Formativa 1]. Universidad Andrés Bello. https://github.com/BenjaArayaM/Proyecto-Lluvias-Australia-Grupo7/blob/7b26b686289a816dc6968c1ba1df44e6191e5e0f/reports/01_formativa1/informe_formativa1_grupo7.pdf

Araya, B., Cañete, A., Cortez, P., & Guaico, J. (2026b). *Sumativa 1 análisis de lluvias en Australia* [Notebook de Python]. GitHub. https://github.com/BenjaArayaM/Proyecto-Lluvias-Australia-Grupo7/blob/7b26b686289a816dc6968c1ba1df44e6191e5e0f/notebooks/02_sumativa1_analisis.ipynb

Bureau of Meteorology. (s. f.). *Definitions for 9am and 3pm statistics*. Recuperado el 13 de octubre de 2026, de https://www.bom.gov.au/climate/cdo/about/definitions9and3.shtml

jsphyg. (s. f.). *Rain in Australia* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/jsphyg/weather-dataset-rattle-package/data

The SciPy community. (s. f.-a). *scipy.stats.chi2_contingency*. Recuperado el 13 de octubre de 2026, de https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.chi2_contingency.html

The SciPy community. (s. f.-b). *scipy.stats.shapiro*. Recuperado el 13 de octubre de 2026, de https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.shapiro.html

The SciPy community. (s. f.-c). *scipy.stats.ttest_1samp*. Recuperado el 13 de octubre de 2026, de https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_1samp.html

Williams, G. (s. f.). *weatherAUS: Daily weather observations from multiple Australian weather stations* [Documentación de Rattle]. Recuperado el 13 de octubre de 2026, de https://search.r-project.org/CRAN/refmans/rattle/html/weatherAUS.html

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association, 22*(158), 209–212. https://doi.org/10.1080/01621459.1927.10502953