

UNIVERSIDAD ANDRÉS BELLO

Magíster en Ciencia de Datos e Inteligencia Artificial

MCDI501
Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 3

Modelamiento Predictivo Integrado

Relación entre condiciones meteorológicas y lluvia al día siguiente

Informe técnico grupal · Grupo 7 · Ponderación 60 %

Integrantes

Benjamín Araya
Alan Cañete
Patricio Cortez
Jorge Guaico

Dataset: Rain in Australia — Weather Australia
Docente: Jean Paul Maidana
Fecha: 24 de octubre de 2026

Repositorio y rama del análisis

https://github.com/BenjaArayaM/Proyecto-Lluvias-Australia-Grupo7

1. Resumen ejecutivo e introducción

Integración de evidencia y decisiones para clasificar RainTomorrow

El modelo seleccionado mediante validación interna alcanza un ROC-AUC de 0,8619, recall de 68,26 % y precision de 57,98 % en los 42.658 registros de prueba. El recall aumenta 28,44 puntos porcentuales respecto de F2, con un cambio de accuracy de -1,09 puntos. La mejora implica un intercambio entre detección y falsas alarmas: todavía quedan 3 035 días lluviosos sin detectar y 4 732 falsas alertas. El remuestreo identifica incertidumbre geográfica que el intervalo convencional subestima para algunos coeficientes.

Problema y alcance

Se estudia la relación entre condiciones meteorológicas de un día registrado y `RainTomorrow`. La aplicación de referencia es una alerta que ayude a planificar actividades sensibles a lluvia. El archivo *Rain in Australia* (s. f.) contiene 145.460 observaciones, 23 columnas y 49 localidades. Las 3.267 respuestas ausentes se excluyen; quedan 142.193 registros etiquetados. Se conserva el archivo original y se documenta su identidad mediante SHA-256. El análisis es retrospectivo: el dataset no certifica una hora operacional de emisión ni disponibilidad en tiempo real de todas las mediciones del día.

Tabla 1: La evidencia anterior determina decisiones verificables de S3.

Fase	Evidencia propia	Decisión en el cierre
S1 y S2	Diferencia media de humedad 20,08 pp; IC bootstrap [18,52; 21,62].	Incorporar `Humidity3pm` e interpretar su asociación ajustada.
S2	MaxTemp–Temp3pm: $\rho = 0,984$, estable bajo remuestreo.	Conservar MaxTemp y excluir Temp3pm de los clasificadores.
S1 y S2	Sunshine ausente en 48,01 % del archivo y en todas las filas de 19 localidades.	Comparar eliminación, mediana y regresión; declarar el supuesto de transporte a estaciones sin datos.
S2	Humedad–Rainfall cambia de 0,444 a 0,307 al filtrar en 2 mm.	Conservar extremos plausibles; evaluar log1p(Rainfall) sin eliminar lluvia legítima.
F2	Recall 39,82 %, AUC 0,8164 y 5.755 falsos negativos.	Ponderar clases y fijar umbrales con predicciones OOF de entrenamiento.

Fuente: elaboración del Grupo 7; datos y cálculos de esta ejecución.

Objetivo integrado

Comparar estrategias de faltantes y tres procedimientos logísticos, evaluar estabilidad de coeficientes y traducir la evidencia a recomendaciones. La partición 70/30 estratificada y la semilla 42 conservan F2: 99.535 registros de entrenamiento y 42.658 de prueba. Los valores de F2 se reprodujeron antes del desarrollo. Los antecedentes exploraron el archivo completo y F2 ya observó la prueba; los resultados describen esta comparación académica y no una validación externa independiente.

2. Manejo de datos faltantes

Regresión múltiple y elección informada de estrategia

Se recuperó la auditoría de S1. Entre respuestas conocidas, Sunshine presenta 47,69 % de ausencia. El patrón por localidad cuestiona MCAR; MAR condicionado a covariables se utiliza como supuesto de trabajo, sin descartar MNAR (Rubin, 1976). La regresión determinista no elimina esta incertidumbre.

Cada una de las 16 variables numéricas incompletas se modeló mediante OLS con tres predictores y casos completos de entrenamiento. Se priorizaron pares validados en S2 y se limitó la redundancia entre predictores. La matriz exportada de S1 cubre siete variables; las relaciones restantes se completaron y rotularon como *ampliación S3 de entrenamiento*. La respuesta futura no participa en ninguna imputación. La validación interna retiene el 20 % de donantes.

Tabla 2: Reconstrucción de variables numéricas en donantes observados de entrenamiento.

Variable	Tres predictores	Donantes	R^2 val.	RMSE reg.	RMSE med.
MinTemp	Temp9am; Evaporation; Pressure3pm	56 512	0,827	2,69	6,48
MaxTemp	Temp3pm; MinTemp; Evaporation	56 017	0,973	1,16	7,06
Rainfall	Humidity3pm; Humidity9am; Sunshine	51 140	0,081	8,50	9,18
Evaporation	MaxTemp; MinTemp; Humidity9am	56 479	0,417	3,27	4,33
Sunshine	Humidity3pm; Cloud3pm; Cloud9am	44 903	0,645	2,23	3,82
WindGustSpeed	WindSpeed3pm; WindSpeed9am; Pressure9am	85 703	0,617	8,27	13,41
WindSpeed9am	WindGustSpeed; WindSpeed3pm; Humidity9am	91 836	0,404	6,69	8,74
WindSpeed3pm	WindGustSpeed; WindSpeed9am; Pressure9am	85 703	0,482	6,15	8,54
Humidity9am	Humidity3pm; Evaporation; Sunshine	48 718	0,543	12,60	18,65
Humidity3pm	Sunshine; Rainfall; Humidity9am	51 140	0,588	13,13	20,45
Pressure9am	Pressure3pm; MinTemp; WindGustSpeed	85 689	0,929	1,87	7,05
Pressure3pm	Pressure9am; Temp9am; WindGustSpeed	85 666	0,932	1,84	7,08
Cloud9am	Sunshine; Cloud3pm; Humidity3pm	44 903	0,495	1,99	2,88
Cloud3pm	Sunshine; Cloud9am; Humidity3pm	44 903	0,541	1,80	2,74
Temp9am	MinTemp; MaxTemp; Evaporation	56 732	0,928	1,78	6,65
Temp3pm	MaxTemp; MinTemp; Evaporation	56 017	0,971	1,17	6,93

Fuente: elaboración del Grupo 7; datos y cálculos de esta ejecución.

En Sunshine, el RMSE baja de 3,822 a 2,226 horas (41,76 %; $R^2 = 0,645$). Se eligió regresión con la regla predefinida de reducción de RMSE de al menos 5 % frente a mediana. La elección utiliza reconstrucción de entrenamiento y cobertura, no el desempeño de prueba. Mediana y eliminación se conservan para el análisis de sensibilidad.

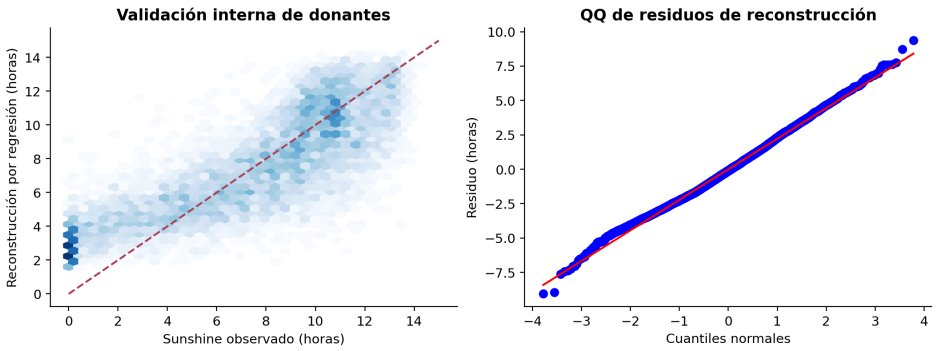


Figura 1: Validación de Sunshine y QQ de residuos: buena reconstrucción no equivale a normalidad ni valida estaciones sin datos.

Si faltan covariables al aplicar una regresión, se usa su mediana auxiliar de entrenamiento: ocurrió en 35 960 de 47 607 imputaciones de Sunshine en train. Los recortes físicos se aplican solo a valores imputados; los observados permanecen intactos. Shapiro y Breusch–Pagan señalan desviaciones de normalidad y homocedasticidad; las regresiones se utilizan para predicción condicional, con cautela inferencial. Los CSV detallan conteos y diagnósticos.

3. Construcción y selección de modelos

Variables informadas por S1/S2 y validación dentro de entrenamiento

M1 conserva Humidity3pm, Sunshine, Rainfall y MaxTemp de F2. M2 aplica stepwise bidireccional AIC a ocho candidatos: los antecedentes se complementan en train con viento, presión, humedad matinal y nubosidad. Log1p(Rainfall) mantiene el orden de las precipitaciones y modera su asimetría sin descartar extremos. M3 minimiza BIC entre los 14 subconjuntos de uno a tres predictores de M1. La restricción hace explícita la solicitud de un modelo reducido: no se presenta como el BIC mínimo entre todas las especificaciones.

AIC y BIC se calculan sin ponderación, sobre las mismas observaciones, según sus penalizaciones por complejidad (Akaike, 1974; Schwarz, 1978). Después se reajusta cada modelo para clasificación con pesos $w_c = n/(2n_c)$: 2,2303 para lluvia y 0,6445 para ausencia (Scikit-learn developers, s. f.). Los scores resultantes no están calibrados automáticamente como probabilidades meteorológicas.

Tabla 3: Selección sobre entrenamiento: AIC/BIC no ponderados y métricas fuera de pliegue.

Modelo	p	AIC	BIC	AUC OOF	Umbral
M1	4	80 289,2	80 336,8	0,8213	0,5638
M2	8	72 746,5	72 832,1	0,8604	0,6034
M3	3	80 848,3	80 886,3	0,8180	0,5776

Fuente: elaboración del Grupo 7; datos y cálculos de esta ejecución.

Los cinco pliegues estratificados reajustan imputación y escalamiento y repiten la selección de variables dentro del entrenamiento interno. Se escoge el mayor AUC OOF; diferencias de hasta 0,002 favorecen menos predictores. Cada umbral maximiza F1 OOF. La especificación y los umbrales quedan registrados antes de predecir prueba. El procedimiento elegido es M2 stepwise AIC, con umbral 0,6034 sobre su score ponderado.

Tabla 4: Coeficientes estandarizados y odds ratios de las tres especificaciones.

Predictor	M1 β (OR)	M2 β (OR)	M3 β (OR)
const	-0,415 (0,660)	-0,579 (0,561)	-0,416 (0,659)
Humidity3pm	0,894 (2,446)	0,902 (2,465)	0,802 (2,230)
Sunshine	-0,660 (0,517)	-0,478 (0,620)	-0,600 (0,549)
Rainfall	0,384 (1,468)	—	0,375 (1,455)
MaxTemp	0,272 (1,313)	0,095 (1,099)	—
WindGustSpeed	—	0,467 (1,596)	—
Pressure3pm	—	-0,486 (0,615)	—
log1p_Rainfall	—	0,258 (1,294)	—
Cloud3pm	—	0,193 (1,213)	—
Humidity9am	—	0,101 (1,106)	—

Fuente: elaboración del Grupo 7; datos y cálculos de esta ejecución.

En el modelo final, aumentar Humidity3pm en 20,60 pp se asocia con multiplicar las odds del ajuste ponderado por 2,465, manteniendo constantes los otros predictores. Para log1p(Rainfall), duplicar $(1 + \text{mm})$ se asocia con OR=1,219. Un OR no multiplica directamente la probabilidad. Los signos ajustados pueden diferir de las correlaciones marginales de S1; no representan efectos causales. El notebook presenta los resúmenes y los intervalos convencionales de las tres especificaciones.

4. Desempeño predictivo

Discriminación, detección de lluvia y falsas alertas

Tabla 5: Desempeño aparente de entrenamiento y de prueba con umbrales F1 OOF.

Modelo	Muestra	Acc.%	Prec.%	Recall%	F1	AUC
M1	train	77,90	50,54	66,65	0,575	0,8214
M1	test	78,06	50,82	66,65	0,577	0,8240
M2	train	81,55	57,52	67,65	0,622	0,8606
M2	test	81,79	57,98	68,26	0,627	0,8619
M3	train	78,32	51,30	64,97	0,573	0,8181
M3	test	78,57	51,76	64,82	0,576	0,8208

Fuente: elaboración del Grupo 7; datos y cálculos de esta ejecución.

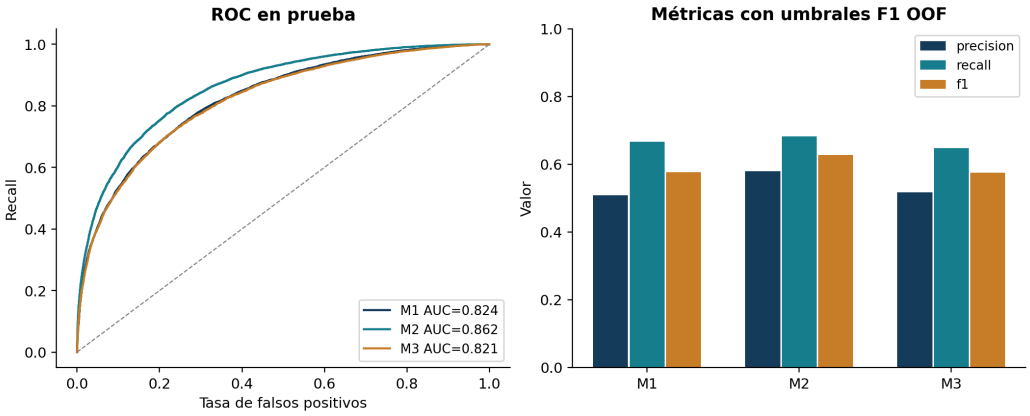


Figura 2: ROC y métricas de prueba. El AUC es discriminación y no porcentaje de clasificaciones correctas.

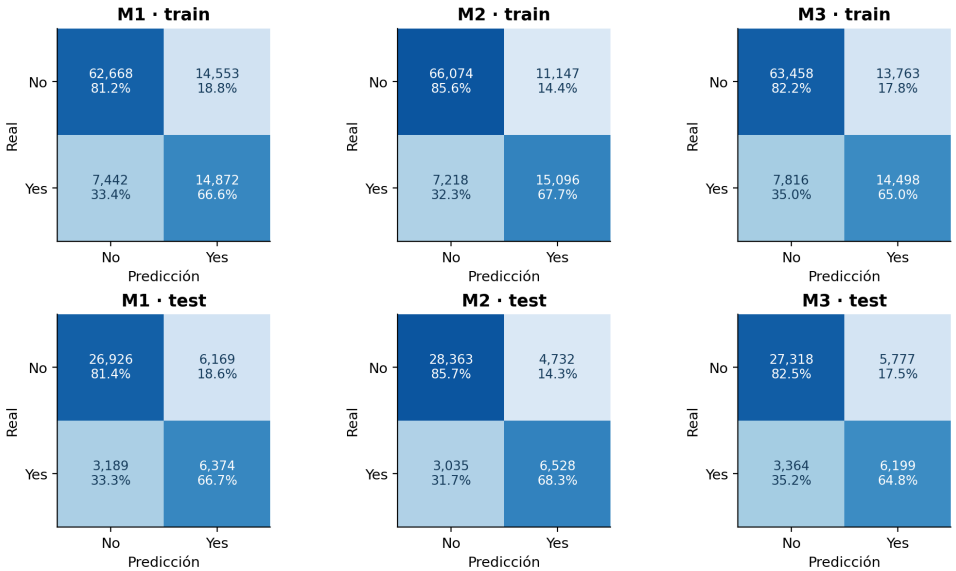


Figura 3: Matrices para los tres modelos en train y test. Filas reales, columnas predichas; conteos y porcentajes por clase real.

El modelo final obtiene accuracy 81,79 %, precision 57,98 %, recall 68,26 %, F1 0,6270 y PR-AUC 0,6872. Detecta 6 528 días de lluvia y omite 3 035. El aumento del recall frente a F2 convive con más falsas alarmas; el uso de alertas requiere valorar ese costo. La mejora cambia variables, imputación, pesos y umbral simultáneamente, por lo que no se atribuye a una única intervención. Se publican además métricas con umbral 0,50 como referencia.

5. Estabilidad de coeficientes

Bootstrap de localidades y comparación con intervalos tradicionales

Se obtuvieron 2 000 remuestras válidas y 0 fallos, remuestreando las 49 localidades de entrenamiento con reemplazo. Sus registros disponibles permanecen juntos. En cada remuestra se reajustan regresiones de imputación, medianas auxiliares, escala y pesos de clase. Se fijan las listas de predictores: la inferencia es condicional a la selección y no incorpora su incertidumbre completa. La independencia entre localidades sigue siendo un supuesto (Cameron y Miller, 2015).

Para acelerar sin modificar el estimador se usan multiplicidades de localidad y estadísticos OLS por conglomerado. Se verificó la equivalencia contra duplicación real de filas y un GLM independiente. Las betas se expresan por la misma DE de referencia, evitando mezclar escalas entre remuestras.

Tabla 6: IC 95 % de betas y OR. Signo% es la frecuencia descriptiva de conservar el signo original.

Predictor	$\hat{\beta}$	IC Wald beta	IC boot beta	OR [IC boot]	Signo%
Humidity3pm	0,902	[0,877; 0,927]	[0,804; 1,025]	2,465 [2,234; 2,787]	100,0
WindGustSpeed	0,467	[0,449; 0,486]	[0,399; 0,547]	1,596 [1,491; 1,729]	100,0
Pressure3pm	-0,486	[-0,506; -0,467]	[-0,602; -0,388]	0,615 [0,548; 0,679]	100,0
Sunshine	-0,478	[-0,506; -0,451]	[-0,550; -0,401]	0,620 [0,577; 0,670]	100,0
log1p_Rainfall	0,258	[0,241; 0,275]	[0,194; 0,308]	1,294 [1,214; 1,360]	100,0
Cloud3pm	0,193	[0,169; 0,217]	[0,117; 0,260]	1,213 [1,124; 1,297]	100,0
MaxTemp	0,095	[0,074; 0,116]	[-0,034; 0,212]	1,099 [0,966; 1,237]	92,6
Humidity9am	0,101	[0,077; 0,125]	[0,011; 0,193]	1,106 [1,011; 1,213]	98,5

Fuente: elaboración del Grupo 7; datos y cálculos de esta ejecución.

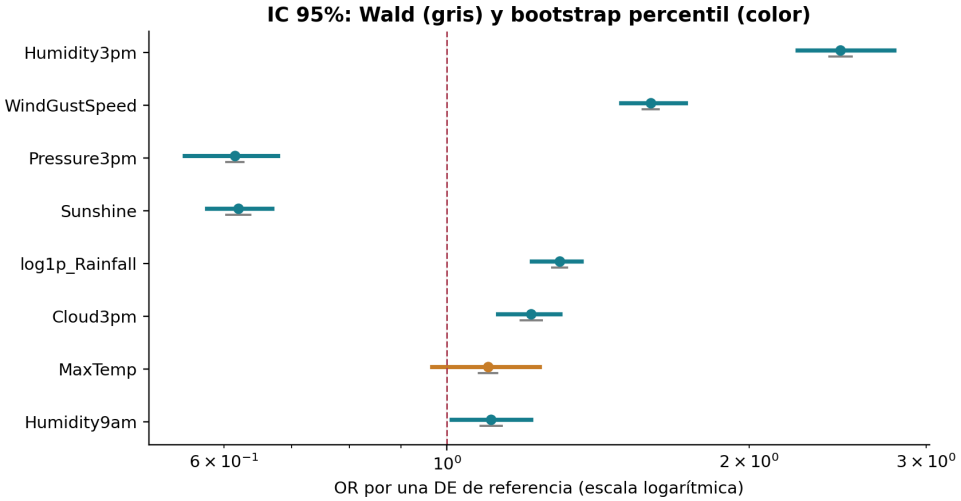


Figura 4: Intervalos Wald y percentil del modelo final. OR=1 indica ausencia de asociación ajustada en esta parametrización.

El intervalo percentil incluye cero para `MaxTemp`; su correspondiente intervalo de OR incluye uno. La comparación con Wald muestra por qué significancia convencional y estabilidad geográfica son preguntas distintas. Humidity3pm conserva una asociación positiva, con OR 2,465 e IC bootstrap [2,234; 2,787] por 20,60 pp. Se calculó también BCa mediante jackknife de 49 localidades y se exportaron distribuciones y convergencia por prefijos. La frecuencia de signo no es una probabilidad posterior. El remuestreo no resuelve MNAR ni confusión no medida.

6. Diagnóstico y alcance inferencial

Multicolinealidad, forma funcional, residuos e influencia

Tabla 7: VIF en entrenamiento preparado.

Predictor	VIF
Humidity3pm	2,561
WindGustSpeed	1,325
Pressure3pm	1,522
Sunshine	3,054
log1p_Rainfall	1,315
Cloud3pm	2,222
MaxTemp	1,856
Humidity9am	2,183

Tabla 8: Box–Tidwell exploratorio y cambio relativo de deviance.

Predictor	p ajustado	Δ dev.%
Humidity3pm	< 0,001	0,154
WindGustSpeed	1,000	0,001
Pressure3pm	1,000	0,001
Sunshine	< 0,001	0,127
log1p_Rainfall	< 0,001	0,132
MaxTemp	0,405	0,004
Humidity9am	0,069	0,007

El VIF máximo es 3,054, sin evidencia de redundancia extrema como la del par MaxTemp–Temp3pm descartado. Las extensiones no lineales detectan desviaciones para algunas variables; sus reducciones relativas de deviance ayudan a separar significancia con gran muestra de importancia práctica. Los valores p son exploratorios bajo el ajuste ponderado y no corrigen la dependencia espacial. Estos diagnósticos no permiten afirmar que la forma lineal del logit sea exacta.

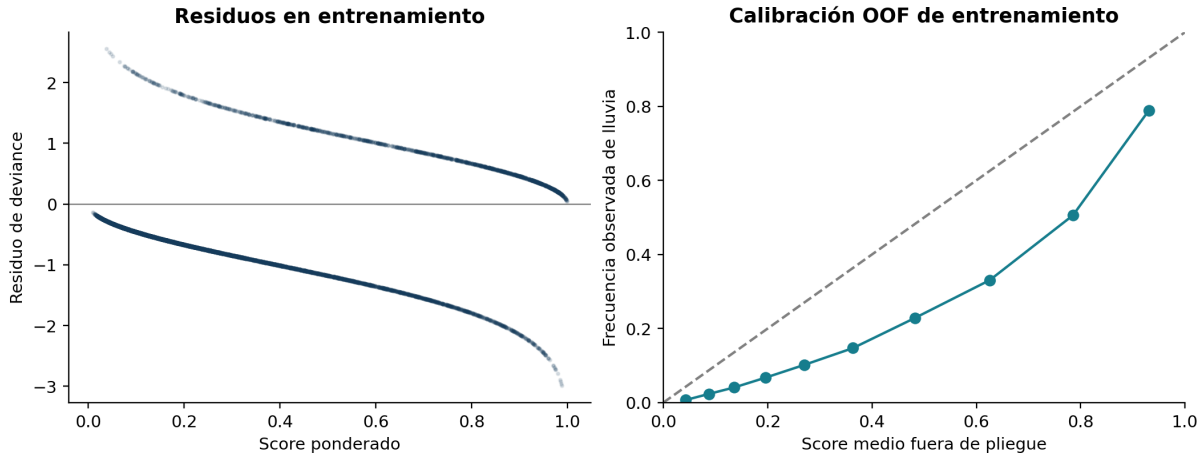


Figura 5: Residuos y calibración OOF. Un AUC favorable puede coexistir con scores que no coinciden con frecuencias observadas.

La regresión logística no exige residuos normales ni homocedásticos. Se examinaron residuos de deviance y Pearson, leverage y Cook. El umbral descriptivo $4/n$ marca 6 417 registros; no se eliminaron automáticamente. La magnitud de las señales y el contexto meteorológico deben acompañar cualquier decisión de depuración. Conservar extremos plausibles responde a la sensibilidad del filtro de S2, que cambiaba la muestra al cortar precipitaciones en 2 mm.

Influencia por localidad

El jackknife identifica MountGinini, Wollongong, Ballarat como las tres localidades con mayor cambio máximo de beta en escala común. Esto indica influencia sobre el ajuste, sin certificar errores de medición. Se publican las 49 omisiones y las 20 observaciones con mayor Cook para revisión trazable.

Interpretación de probabilidades

La ponderación de clases modifica el objetivo del ajuste. La curva de calibración OOF evidencia la distancia entre score y frecuencia real de lluvia. En este trabajo el score sirve para ordenar y clasificar con un umbral validado internamente; su uso como probabilidad operacional requiere calibración y validación adecuadas al horizonte y al contexto de decisión.

7. Impacto de la imputación

Misma especificación, umbral y escala de interpretación

Tabla 9: Comparación sobre prueba propia y sobre los mismos casos comunes.

Estrategia	Prueba	n_{train}	n_{test}	Loc.	AUC	Acc.%	Recall%
Eliminación	Propia	42 282	18 234	27	0,8813	82,83	70,98
Eliminación	Común	42 282	18 234	27	0,8813	82,83	70,98
Mediana	Propia	99 535	42 658	49	0,8589	81,68	67,75
Mediana	Común	99 535	18 234	27	0,8801	82,14	73,49
Regresión	Propia	99 535	42 658	49	0,8619	81,79	68,26
Regresión	Común	99 535	18 234	27	0,8809	82,98	70,96

Fuente: elaboración del Grupo 7; datos y cálculos de esta ejecución.

La eliminación cubre 42,74 % de prueba y 27 localidades. Un AUC superior en esa muestra no demuestra superioridad sobre estrategias que cubren las 49 localidades. Los casos comunes permiten comparar procedimientos sobre idénticos registros; aun así, describen una subpoblación con mayor completitud de medición.

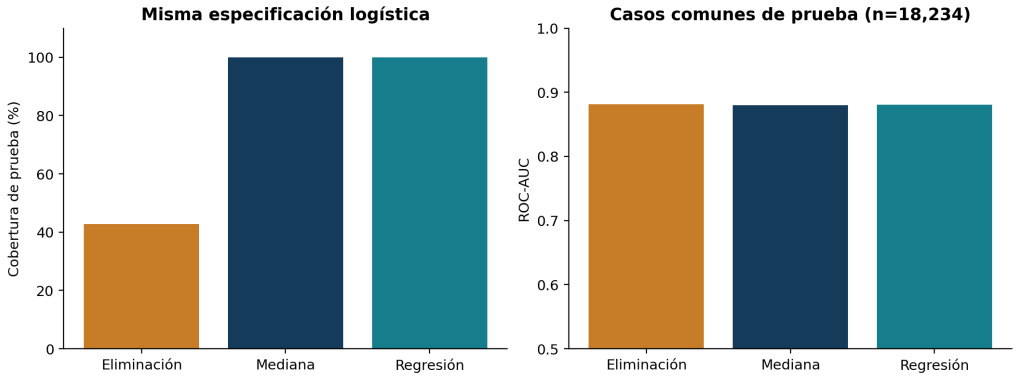


Figura 6: Cobertura y AUC sobre casos comunes. El tamaño y la composición de la población importan para interpretar la diferencia.

Tabla 10: Betas e IC Wald del modelo final por la misma DE de referencia.

Predictor	Eliminación	Mediana	Regresión
Humidity3pm	0,967 [0,926; 1,009]	1,013 [0,989; 1,036]	0,902 [0,877; 0,927]
WindGustSpeed	0,519 [0,490; 0,549]	0,488 [0,470; 0,507]	0,467 [0,449; 0,486]
Pressure3pm	-0,492 [-0,524; -0,461]	-0,489 [-0,508; -0,470]	-0,486 [-0,506; -0,467]
Sunshine	-0,488 [-0,520; -0,455]	-0,383 [-0,404; -0,362]	-0,478 [-0,506; -0,451]
log1p_Rainfall	0,191 [0,164; 0,219]	0,234 [0,217; 0,251]	0,258 [0,241; 0,275]
Cloud3pm	0,245 [0,213; 0,276]	0,287 [0,266; 0,308]	0,193 [0,169; 0,217]
MaxTemp	0,108 [0,072; 0,143]	0,067 [0,046; 0,087]	0,095 [0,074; 0,116]
Humidity9am	0,070 [0,029; 0,111]	0,148 [0,124; 0,172]	0,101 [0,077; 0,125]

Fuente: elaboración del Grupo 7; datos y cálculos de esta ejecución.

La imputación por mediana concentra Sunshine y reduce su variación. La regresión conserva variación asociada a covariables, aunque produce encogimiento y depende de supuestos de transporte. La estrategia principal se eligió por reconstrucción de entrenamiento y conservación de cobertura. La comparación predictiva constituye un análisis de sensibilidad de esa decisión, manteniendo predictores y umbral. La ausencia estructurada y la incertidumbre sobre valores no observados impiden interpretar cualquier imputación como recuperación de la verdad meteorológica.

8. Simulación para una decisión de planificación

Ampliación S3 que incorpora la retroalimentación de S2

La simulación de S2 describía una media. En el cierre se formula una decisión explícita: cuánta capacidad para atender días lluviosos se necesita en un escenario hipotético de 30 días, aceptando 5 % de riesgo de excedencia. El riesgo es un supuesto de planificación, no un requisito operacional observado.

Se estiman frecuencias solo en entrenamiento con Humidity3pm observado: 58,34 % cuando la humedad es al menos 70 % y 13,57 % cuando es menor. Bajo días iid y parámetros fijos, $D \sim \text{Binomial}(30, \widehat{p})$. Se generan 10.000 escenarios por grupo, se contrasta la media con $30\widehat{p}$ y se toma el cuantil discreto superior del 95 % como capacidad de referencia.

Tabla 11: Calibración de entrenamiento, resultados Monte Carlo y capacidad de referencia.

Humedad	n train	p lluvia	Media /30	Capacidad 95%	MCSE
Alta	18 924	0,5834	17,52	22	0,027
Menor	78 075	0,1357	4,04	7	0,019

Fuente: elaboración del Grupo 7; datos y cálculos de esta ejecución.

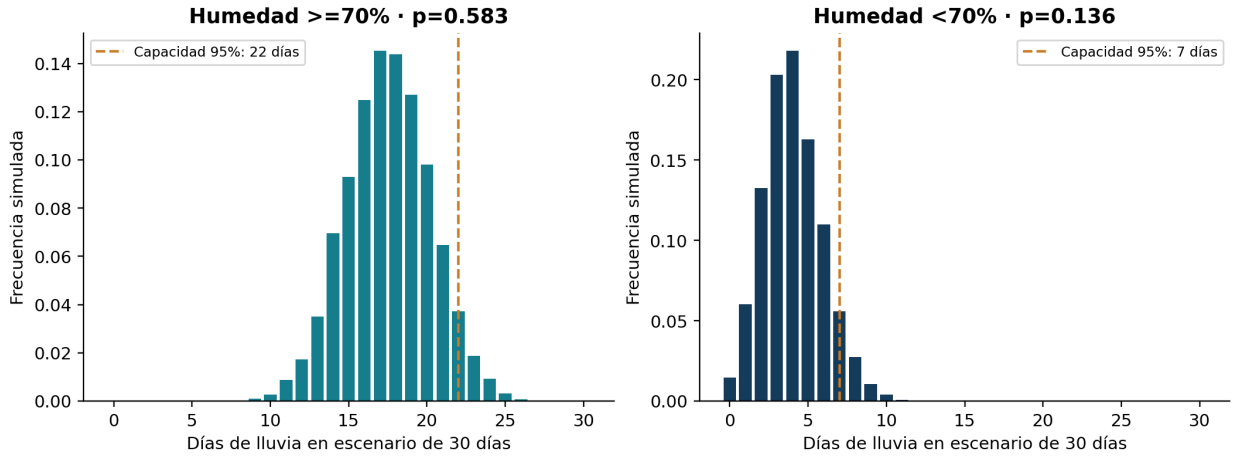


Figura 7: Distribución del número de días lluviosos y capacidad que cubre al menos el 95 % de los escenarios simulados.

Las medias son 17,52 y 4,04 días; las capacidades resultan 22 y 7 días, respectivamente. El resultado informa una reserva de recursos bajo condiciones estipuladas y hace explícita la tolerancia al riesgo. Las tablas registran convergencia, MCSE y probabilidad analítica de exceder 15 días. Una ausencia de excedencias en 10.000 simulaciones no implica probabilidad nula: se informa también la cota binomial de Monte Carlo.

Discusión integrada

S1 caracteriza asociaciones y faltantes; S2 evalúa su estabilidad y muestra sensibilidad al rango de lluvia; F2 establece una referencia predictiva; S3 compara procedimientos, detecta coeficientes inestables y explicita decisiones. La simulación no pronostica 30 fechas futuras: ignora dependencia diaria, estacionalidad y parte de la incertidumbre de p. La partición aleatoria exigida evalúa la muestra disponible. La generalización temporal y geográfica queda como limitación, conforme al alcance indicado por el docente.

9. Conclusiones y reproducción

Recomendaciones sustentadas por el proyecto completo

- **Detección y errores.** El procedimiento M2 stepwise AIC alcanza AUC 0,8619 y recall 68,26 %. Su uso debe valorar conjuntamente 3 035 omisiones y 4 732 falsas alertas; accuracy aislada no sustenta una decisión de alerta.
- **Cobertura y faltantes.** Se recomienda conservar la comparación con mediana y comunicar la dependencia de Sunshine respecto de estación. La eliminación reduce cobertura a 42,74 %; la imputación no sustituye medición.
- **Incertidumbre.** La estabilidad de Humidity3pm contrasta con `MaxTemp`. El intervalo por localidad complementa la inferencia convencional y mantiene visibles sus supuestos.
- **Aplicación.** Antes de operar se requiere definir horizonte, disponibilidad de variables, costos de errores y calibración. La capacidad 22/7 corresponde únicamente al escenario simulado.

Trazabilidad y reproducción

El notebook maestro declara semillas 42 y 50101–50104, cinco pliegues y 2.000 remuestras válidas. El código, tablas, figuras y JSON permiten reconstruir los resultados; las evidencias separan Work y Windows. El SHA-256 del original es `573fd715cd69fcacc4df32024d823b450ae3edaae7e8ff2eeb623adbed424014`. Las instrucciones de instalación y la auditoría de los seis criterios acompañan el repositorio. La participación real en el video y la entrega en Canvas requieren sus evidencias específicas.

Referencias

Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control, 19*(6), 716–723. https://doi.org/10.1109/TAC.1974.1100705

Cameron, A. C., & Miller, D. L. (2015). A practitioner's guide to cluster-robust inference. *Journal of Human Resources, 50*(2), 317–372. https://doi.org/10.3368/jhr.50.2.317

Rain in Australia. (s. f.). Kaggle. https://www.kaggle.com/datasets/jsphyg/weather-dataset-rattle-package

Rubin, D. B. (1976). Inference and missing data. *Biometrika, 63*(3), 581–592. https://doi.org/10.1093/biomet/63.3.581

Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics, 6*(2), 461–464. https://doi.org/10.1214/aos/1176344136

Scikit-learn developers. (s. f.). *compute_class_weight.* https://scikit-learn.org/stable/modules/generated/sklearn.utils.class_weight.compute_class_weight.html